

SK네트웍스 Family AI 과정 21기

데이터 전처리 인공지능 데이터 전처리 결과서

산출물 단계	데이터 전처리
평가 산출물	인공지능 데이터 전처리 결과서
제출 일자	2026-02-25
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN21_FINAL_1team
작성 팀원	이명준

1. 문서 개요

- 프로젝트명: Kalpie
- 전처리 목적: Open LLM 모델의 성능 평가 데이터셋 구축 및 NotebookLM 방식의 웹 소스 추가 기능에 대한 POC
- 문제 정의: Kalpie 웹사이트에서 사용자의 북마크를 받아온 url을 크롤링함. 크롤링된 웹사이트를 각각 청킹한 후 임베딩 모델을 거쳐서 나온 데이터를 RAG로 사용하기 위한 가상의 환경을 산정했음. 또한 구축한 데이터셋은 오픈소스 LLM 중 동일한 GPU 자원을 이용하는 모델을 평가하기 위해 사용.

2. 데이터셋 개요

- 데이터 출처 및 수집 방법:
예: 한국어 위키백과 내 인공지능, 기계학습, 딥러닝 등 관련 문서 15개
- 데이터 구성:

항목명	설명	예시
content_id	문서 식별자	doc_001
title	위키백과 문서 제목	인공지능
section	추출된 섹션 헤더	강인공지능과 약인공지능
context	chunk	"강인공지능(strong AI)은..."
question	합성 생성된 평가용 질문	"강인공지능의 정의를 설명해주세요."
reference_answer	평가용 정답	"강인공지능은 인간과 유사한..."
question_type	질문 유형	definition, summarization 등

- 원본 데이터 샘플(5~10건 첨부):

```
TARGET_URLS = [
    "https://ko.wikipedia.org/wiki/%EC%9D%B8%EA%B3%B5%EC%A7%80%EB%8A%A5",
    "https://ko.wikipedia.org/wiki/%EA%B8%B0%EA%B3%84_%ED%95%99%EC%8A%B5",
    "https://ko.wikipedia.org/wiki/%EC%9E%90%EC%97%B0%EC%96%B4_%EC%B2%98%EB%A6%AC",
    "https://ko.wikipedia.org/wiki/%EB%94%A5_%EB%9F%AC%EB%8B%9D",
    "https://ko.wikipedia.org/wiki/%ED%8A%B8%EB%9E%9C%EC%8A%A4%ED%8F%AC%EB%A8%B8_(%EB%AA%A8%EB%8D%B8)",
    "https://ko.wikipedia.org/wiki/%EB%8C%80%ED%98%95_%EC%96%B8%EC%96%B4_%EB%AA%A8%EB%8D%B8",
    "https://ko.wikipedia.org/wiki/%EC%BB%B4%ED%93%A8%ED%84%B0_%EB%B9%84%EC%A0%84",
    "https://ko.wikipedia.org/wiki/%EA%B0%95%ED%99%94_%ED%95%99%EC%8A%B5",
    "https://ko.wikipedia.org/wiki/%EC%8B%A0%EA%B2%BD%EB%A7%9D",
    "https://ko.wikipedia.org/wiki/%ED%95%A9%EC%84%B1%EA%B3%B1_%EC%8B%A0%EA%B2%BD%EB%A7%9D",
    "https://ko.wikipedia.org/wiki/%EC%88%9C%ED%99%98_%EC%8B%A0%EA%B2%BD%EB%A7%9D",
    "https://ko.wikipedia.org/wiki/%EC%83%9D%EC%84%B1%EC%A0%81_%EC%A0%81%EB%8C%80_%EC%8B%A0%EA%B2%BD%EB%A7%9D",
    "https://ko.wikipedia.org/wiki/%EC%96%B4%ED%85%90%EC%85%98_(%EA%B8%B0%EA%B3%84_%ED%95%99%EC%8A%B5)",
    "https://ko.wikipedia.org/wiki/%EB%B2%A1%ED%84%B0_%EB%8D%B0%EC%9D%B4%ED%84%B0%EB%B2%A0%EC%9D%B4%EC%8A%A4",
    "https://ko.wikipedia.org/wiki/%EC%9E%84%EB%B2%A0%EB%94%A9",
]
```



1월 28일부터 2월 28일까지 2026년 동계 올림픽 에디터톤이 진행됩니다.

인공지능

총 173개 언어

목차 숨기기

문서 토론

읽기 원본 보기 역사 보기 도구

보이기 숨기기

처음 위치

위키백과, 우리 모두의 백과사전.



AI는 여기로 연결됩니다. 조류가 걸리는 호르몬 질병에 대해서는 **조류 인플루엔자** 문서를, 다른 뜻에 대해서는 **AI (동음이의)** 문서를 참고하십시오.

[[W]] 위키백과의 인공지능에 대해서는 **위키백과:인공지능** 문서를 참고하십시오.

인공지능(人工智能, 영어: artificial intelligence, AI)은 인간의 학습능력, 추론능력, 지각능력 등을 인공지능으로 구현하려는 **컴퓨터 과학**의 세부분야 중 하나이다. 정보공학 분야에 있어 하나의 **인프라** 기술이기도 하다.^{[1][2]} 인간을 포함한 동물이 갖고 있는 지능 즉, 자연 지능(natural intelligence)과는 다른 개념이다.

인간의 지능을 모방한 기능을 갖춘 **컴퓨팅 시스템**이며, 인간의 지능을 기계 등에 인공적으로 시연(구현)한 것이다. 일반적으로 범용 컴퓨터에 적용한다고 가정한다. 이 용어는 또한 그와 같은 지능을 만들 수 있는 방법론이나 실현 가능성 등을 연구하는 과학 기술 분야를 지칭하기도 한다.^{[3][4][5]}

강인공지능과 약인공지능

초기 인공지능 연구에 대한 대표적인 정의는 님스 회의에서 존 매카시가 제안한 것으로 "기계를 인간 행동의 지식에서와 같이 행동하게 만드는 것"이다. 그러나 이 정의는 **범용인공지능**

시리즈의 일부

인공지능 (AI)

주요 목표	[펼치기]
접근 방식	[펼치기]
애플리케이션	[펼치기]
철학	[펼치기]
역사	[펼치기]
논란	[펼치기]

- ☐ 작음
- ☒ 표준
- ☐ 큼
- 너비
- ☒ 표준
- ☐ 넓게
- 색 (베타)
- ☐ 자동
- ☒ 라이트
- ☐ 다크

딥 러닝

총 64개 언어

목차 숨기기

문서 토론

읽기 편집 역사 보기 도구

처음 위치

위키백과, 우리 모두의 백과사전.

심층 학습(深層學習) 또는 **딥 러닝**(영어: deep structured learning, deep learning 또는 hierarchical learning)은 여러 '비선형 변환기법'의 조합을 통해 높은 수준의 추상화(abstractions, 다량의 데이터나 복잡한 자료들 속에서 핵심적인 내용 또는 기능을 요약하는 작업)를 시도하는 **기계 학습 알고리즘**의 집합^[1]으로 정의되며, 큰 틀에서 사람의 사고방식을 컴퓨터에게 가르치는 기계학습의 한 분야라고 이야기할 수 있다.

어떠한 데이터가 있을 때 이를 컴퓨터가 알아 들을 수 있는 형태(예를 들어 이미지의 경우는 픽셀정보를 **열벡터**로 표현하는 등)로 표현(representation)하고 이를 학습에 적용하기 위해 많은 연구(어떻게 하면 더 좋은 표현기법을 만들고 또 어떻게 이것들을 학습할 모델을 만들지에 대한)가 진행되고 있으며, 이러한 노력의 결과로 deep neural networks, convolutional deep neural networks, deep belief networks와 같은 다양한 딥 러닝 기법들이 **컴퓨터 비전**, 음성 인식, 자연어 처리, 음성/신호처리 등 최첨단 분야에 적용되고 있다.

2012년 **스탠포드대학**의 **앤드류 응**과 **구글**이 함께한 딥 러닝 프로젝트에서는 16,000개의 컴퓨터 프로세서와 10억 개 이상의 neural networks 그리고 DNN(deep neural networks)을 이용하여 유튜브에 업로드 되어 있는 천만 개 넘는 비디오 중 고양이 인식에 성공하였다.^[2] 이 소프트웨어 프레임워크를 논문에서는 DistBelief로 언급하고 있다^[3]. 이뿐만 아니라 **마이크로소**

기계 학습과 데이터 마이닝

패러다임	[펼치기]
문제	[펼치기]
지도 학습 (통계적 분류 · 회귀 분석)	[펼치기]
클러스터 분석	[펼치기]
차원 축소	[펼치기]
구조적 예측	[펼치기]
이상 탐지	[펼치기]
인공 신경망	[펼치기]

알고리즘

심층 신경망(Deep Neural Network, DNN)

심층 신경망의 문제점

합성곱 신경망(Convolutional Neural Network, CNN)

순환 신경망

각주 [편집]

세계 IT 시장 10대 주요 예측^[6]에 포함시키는 등 최근들어 딥 러닝에 대한 관심이 높아지고 있지만 사실 딥 러닝 구조는 인공신경망(ANN, artificial neural networks)에 기반하여 설계된 개념으로 역사를 따지자면 최소 1980년 Kunihiko Fukushima에 의해 소개된 Neocognitron^[7]까지 거슬러 올라가야 한다. 맥컬락-윌터 피츠는 1943년에 ANN의 가능성을 처음으로 주장했다. 1957년에 미국의 신경 생물학자인 프랑크 로젠블랫은 이 개념을 실증하는데 성공했고 퍼셉트론이라 불렀다. 그러나 당시 성능이 너무 후져서 묻혔다가, 힌튼이 역전파 알고리즘을 이용하여 1995년에 다시 ANN이 부활하게 되었다.

1989년에 안 르쿤과 그의 동료들은 오류역전파 알고리즘(backpropagation algorithm)^[8]에 기반하여 우편물에 손으로 쓰여진 우편번호를 인식하는 deep neural networks를 소개^[9]했다. 알고리즘이 성공적으로 동작했음에도 불구하고, 신경망 학습에 소요되는 시간(10 개의 숫자

- ↑ Y. Bengio, A. Courville, and P. Vincent., "Representation Learning: A Review and New Perspectives," IEEE Trans. PAMI, special issue Learning Deep Architectures, 2013
- ↑ How Many Computers to Identify a Cat? 16,000 http://www.nytimes.com/2012/06/26/technology/in-a-big-network-of-computers-evidence-of-machine-learning.html?_r=2&_amp&_
- ↑ "보관된 사본". 2014년 7월 6일에 원본 문서에서 보존된 문서. 2014년 7월 8일에 확인함.
- ↑ <http://techcrunch.com/2013/12/09/facebook-artificial-intelligence-lab-lecun/>
- ↑ MIT, 올해의 10대 혁신기술 선정 <http://news.donga.com/3/all/20130426/54713529/1>
- ↑ 가트너, 2014 세계 IT 시장 10대 주요 예측 발표 <http://www.acrof.com/ko-kr/commerce/news/20131013/00000015>
- ↑ Neocognitron: A Self-organizing Neural Network Model for a Mechanism of Pattern Recognition Unaffected by Shift in Position <http://www.cs.princeton.edu/courses/archive/spr08/cos598B/Readings/Fukushima1980.pdf>
- ↑ P. Werbos., "Beyond Regression: New Tools for Prediction and Analysis in the Behavioral Sciences," PhD thesis, Harvard University, 1974.
- ↑ LeCun et al., "Backpropagation Applied to Handwritten Zip Code Recognition," Neural Computation, 1, pp. 541-551, 1989. <https://www.ics.uci.edu/~welling/teaching/273ASpring09/lecun-89e.pdf> [보관됨](#) 2015-05-29 - 웨이백 머신
- ↑ S. Hochreiter., "Untersuchungen zu dynamischen neuronalen Netzen," Diploma thesis. Institut f. Informatik,
- ↑ Deng, L.; Platt, J. (2014). "Ensemble Deep Learning for Speech Recognition". Proc. Interspeech.
- ↑ Yu, D.; Deng, L. (2010). "Roles of Pre-Training and Fine-Tuning in Context-Dependent DBN-HMMs for Real-World Speech Recognition". NIPS Workshop on Deep Learning and Unsupervised Feature Learning.
- ↑ Deng L., Li, J., Huang, J., Yao, K., Yu, D., Seide, F. et al. Recent Advances in Deep Learning for Speech Research at Microsoft. ICASSP, 2013.
- ↑ Yu, D.; Deng, L. (2014). "Automatic Speech Recognition: A Deep Learning Approach (Publisher: Springer)".
- ↑ Deng, L.; Li, Xiao (2013). "Machine Learning Paradigms for Speech Recognition: An Overview". IEEE Transactions on Audio, Speech, and Language Processing.
- ↑ L. Deng and D. Yu (2014) "Deep Learning: Methods and Applications" <http://research.microsoft.com/pubs/209355/DeepLearning-NowPublishing-Vol7-SIG-039.pdf>
- ↑ McMillan, R. "How Skype Used AI to Build Its Amazing New Language Translator", Wire, Dec. 2014.
- ↑ Hannun et al. (2014) "Deep Speech: Scaling up end-to-end speech recognition", arXiv:1412.5567.
- ↑ Ron Schneiderman (2015) "Accuracy, Apps Advance Speech Recognition --- Interview with Vlad Sejnoha and Li Deng", IEEE Signal Processing Magazine, Jan, 2015.
- ↑ D. Ciresan, U. Meier, J. Schmidhuber., "Multi-column Deep Neural Networks for Image Classification," Technical Report No. IDSIA-04-12', 2012.

3. 전처리 프로세스 개요

● 전체 흐름도:

① 크롤링 → ② 전처리 → ③ 텍스트 정제 → ④ 분할 → ⑤ 데이터 합성 → ⑥ 적재

● 전처리 파이프라인 요약:

단계	목적	수행 작업	사용 도구/라이브러리
크롤링	웹 소스 수집	Wikipedia Crawling	Requests, BS4
전처리	비정상 데이터 제거	영어와 한국어를 제외한 다른 문자, 문서와 의미론적으로 다른 글자 제거	Python, Claude cli
텍스트 정제	노이즈 제거	사이드 바, 페이지 네비게이션 등	Re, python

		잔여물 및 특수문자 정리	
분할	의미 단위 청킹	마크다운 (#) 기준 분할 및 문장 단위 재분할	python
데이터 합성	LLM-as-Judge 평가 데이터셋 구축	컨텍스트 기반 QA 및 reference_answer 합성 데이터 생성	Claude cli
적재	Csv 형식으로 저장	Csv 형식으로 저장 및 버저닝	Os, pathlib

4. 세부 전처리 단계

4.1 텍스트 정제 및 노이즈 제거

- 정제 대상 및 기준:
 - 위키백과 특수 요소: `mw-editsection`(편집 링크), `reflist`(각주 목록), `[편집]` 텍스트 등 가독성을 해치는 요소 제거.
 - 하이퍼링크 오류: 존재하지 않는 문서로 연결되는 `class="new"`(빨간 링크) 텍스트의 혼입 방지.
 - 사이드바/네비게이션: 본문 시작 전 나열되는 주제별 링크 블록(`remove_sidebar_content`)을 식별하여 제거.
- 처리 방식 및 영향:
 - 정규표현식(`re`)과 `BeautifulSoup4`를 활용한 태그 및 패턴 기반 제거.
 - v1 대비 v2에서 원본 데이터 크기를 약 **31%** 감소(298KB → 206KB)시켜 고밀도의 텍스트 정보만 확보함.

4.2 의미 단위 청킹 (Section-based Chunking)

- 분할 로직 및 기준:
 - 섹션 기반 분할: 단순 글자 수 기준이 아닌, 위키 마크다운의 `##` 헤더를 기준으로 주제별 1차 분할 수행.
 - 길이 제한 및 재분할: 단일 섹션이 800자를 초과할 경우에만 문장 경계를 탐색하여 2차 분할을 수행하며, 80자 미만의 짧은 청크는 제외함.
- 코드 예시 (Python):

```

Python
# 섹션 기반 분할 로직 예시
def split_by_sections(text):
    sections = text.split('##')
    return [s.strip() for s in sections if len(s.strip()) >= 80]

# 긴 섹션 문장 단위 재분할
if len(section_text) > 800:
    chunks = split_long_section(section_text, max_len=800)
  
```

4.3 평가용 합성 데이터(Q&A) 생성

- 데이터 생성 전략:
 - Definition:** "용어(English)"와 같은 괄호 패턴을 추출하여 개념 정의형 질문 생성 (162건).
 - Summarization:** 섹션 제목을 활용하여 해당 단락의 전체 내용을 묻는 요약형 질문 생성

- (97건).
 - **Temporal:** "YYYY년" 패턴을 기반으로 시계열적 사실 관계를 묻는 질문 생성 (100건).
- 데이터 변환 및 생성 결과:
 - **Reference Answer:** Judge LLM이 모델의 답변을 채점할 수 있는 'Golden Answer'를 컨텍스트 기반으로 자동 생성하여 추가.
 - **Question Type:** 각 데이터에 질문 유형 레이블을 부여하여 모델의 영역별 성능 분석이 가능하도록 함.

4.4 데이터 적재 및 버전 관리

- 최종 데이터 수: 368건의 정제된 Q&A 쌍 (v3 기준).
- 적재 방식: `os`, `pathlib` 라이브러리를 사용하여 `data/processed/processed_v3.csv` 경로에 저장 및 버전별 이력 관리.

5. 전처리 결과 요약 및 평가

- 향후 활용 방안:
 - 텍스트 분류, 대화 응답 분기 조건 설계, LLM 학습데이터 구축 등에 사용

6. 변경 이력