

데이터 전처리 인공지능 학습 결과서

산출물 단계	데이터 전처리
평가 산출물	인공지능 학습 결과서
제출 일자	2026-02-25
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN21_FINAL_1team
작성 팀원	이명준, 우재현

1. LLM Model

1.1. 오픈소스 LLM 모델 선정 기준

- 언어적 등가성: 한국어와 영어 웹 문서가 혼재된 비즈니스 환경에서 두 언어에 대해 지식 손실 없이 고품질의 결과를 도출되어야 함.
- 제한된 하드웨어(VRAM)(가정) 내에서의 구동 효율성: RunPod의 RTX 4090/5090과 같은 24GB/32GB VRAM 혹은 32B 파라미터 규모의 모델을 4비트 또는 8비트로 양자화하여 사용하는 것이 가장 이상적인 '스위트 스팟'임.
- 긴 컨텍스트 윈도우 지원과 어텐션 효율성: RAG 시스템은 수만 토큰에 달하는 검색 문서를 입력받아야 하므로, 정보가 누락되는 '중간 실종(Lost in the Middle)' 현상 없이 문서 전체의 맥락을 파악하고 KV 캐시(Cache) 증가를 억제할 수 있는 아키텍처가 중요함.
- 추론 모드(Reasoning Mode)의 유무: 모델이 단순한 텍스트 생성을 넘어 자체적인 사고 과정을 통해 논리적 모순을 식별하고 RAG 답변의 신뢰도를 높일 수 있어야 함

1.2. LGAI-EXAONE/EXAONE-4.0 선정이유

- 압도적인 다국어(한국어-영어) **RAG** 성능: 설계 단계부터 한국어와 영어 데이터 비중을 1:1로 맞춘 14조 개의 토큰을 학습하여, 두 언어 간의 지식 불균형을 원천적으로 해결한 최고 수준의 모델임.
- 하이브리드 어텐션(**Hybrid Attention**) 구조를 통한 메모리 최적화: 국소 어텐션과 전역 어텐션을 3:1 비율로 결합하여, 최대 131,072(131k) 토큰의 긴 참고 문서를 입력받을 때 급증하는 KV 캐시 메모리를 효과적으로 억제하면서도 문맥 파악 능력을 유지함.
- 유연한 추론 모드(**Reasoning Mode**) 지원: 답변의 근거가 되는 구절을 인용하고 논리적 추론 과정을 태그 내에 명시적으로 생성할 수 있어, 답변의 투명성을 높이고 거짓 정보(Hallucination)를 방지하는 전문적인 RAG 시나리오에 완벽히 부합.
- **VRAM** 예산에 부합하는 최적의 체급: 30.95B의 파라미터를 갖춘 이 모델은 24~32GB+ VRAM 환경에 완벽히 들어맞아 고도화된 논리 구조를 활용하면서도 비용 효율적인 서빙이 가능함.

1.3. LLM 결론 및 향후 계획

- 현재 선정 모델: **LGA-EXAONE/EXAONE-4.0-32B-FP8**, 기술적 정확성과 언어적 균형을 위해 LGAI-EXAONE/EXAONE-4.0-32B 모델에 FP8(8비트) 양자화를 적용한 버전을 선정함. 또한, 해당 모델은 양자화를 통해 모델 가중치가 차지하는 메모리 사용량을 절감하여, 남은 VRAM 공간을 RAG의 긴 문서 처리를 위한 KV 캐시로 넉넉하게 확보가 가능함.
- 활용방안: 웹소스 요약 및 사용자 질문에 답변(QA) 선정된 모델을 기반으로 웹 소스(HTML 등)를 파싱 및 시맨틱 청킹(Semantic Chunking)하여 벡터 데이터베이스에 저장한 뒤 연동하는 RAG 아키텍처를 구현함. 다국어 웹 문서를 크로스 참조하여 방대한 컨텍스트 속에서 핵심 정보를 추출하고, EXAONE 4.0의 추론 모드를 결합해 정확한 사실 관계를 기반으로 한 구조화된 문서 요약 및 질의응답(QA) 서비스를 제공할 예정.

- 향후 계획:
 - 테스트 데이터로 실사용 환경 평가 예정: 추후 모델이 실제 서비스 환경에서 **RAG** 답변을 얼마나 정확하게 생성하는지 자체 테스트 데이터로 정밀하게 평가할 계획임. 이 과정에서 상용 폐쇄형 **API**(예: **GPT-4o** 등)를 '평가자(LLM-as-a-Judge)'로 활용하여 로컬 모델이 생성한 요약 및 답변의 품질을 객관적으로 검증하는 대조군 실험도 진행중.
 - 경량화된 모델 고려: 복잡한 추론이 필요 없는 단순 정보 추출이나 높은 처리 속도가 요구되는 구간에서는, **TinyBERT**와 같은 지식 증류(**Distillation**) 기반의 경량화 모델이나 **EXAONE-3.0 (7.8B)** 같은 초경량 모델의 하이브리드 도입을 검토하여 연산 효율을 극대화할 예정.
 - **Runpod GPU** 병렬 처리 및 고성능 모델 사용 시와 현재 모델간의 비교 및 평가: 서비스 확장에 대비하여 단일 **GPU(24-32GB)**를 사용하는 현재 환경과, **A100/H100** 고성능 멀티 **GPU**, 혹은 **RTX5090**을 2개 이상 활용한 병렬 처리 등 다양한 환경 간의 속도 및 가성비를 비교 평가할 예정임. 또한 타 아키텍처(예: **DeepSeek-R1** 증류 모델, **70B**급 대형 모델)와 **EXAONE 4.0** 간의 **RAG** 성능 비교 혹은 **EXAONE** 각 양자화 모델 간의 멀티홉 **RAG** 성능 비교도 지속적으로 수행할 것임.
 - **Vllm** 서빙과 비동기 스트리밍 방식의 **API**구축: 프론트엔드와 원활하게 통신하기 위해 도커(**Docker**) 컨테이너 기반의 **vLLM** 프레임워크를 **RunPod**에 배포하여 **FastAPI** 기반의 비동기 스트리밍 형태의 **API**를 구축하고 백엔드에 연결해 배포환경에 적절한 서비스를 구축할 것임. **vLLM**의 **PagedAttention** 기술을 통해 다중 사용자 접속 시의 메모리 파편화를 방지하고, 쿼즈나 요약 결과를 프론트엔드에서 파싱 가능한 **JSON** 형식으로 출력하도록 시스템을 고도화할 계획임.

2. Embedding Model

2.1 선정 기준

- 다국어 지원: 한국어와 영어 혼합 문서(위키피디아, 기술 블로그 등)를 동일 벡터 공간에서 처리해야 함

- 최대 토큰 수: 청킹 단위가 1,000자(약 300~500토큰)이므로, 긴 청크도 잘림 없이 인코딩할 수 있어야 함
- 벡터 차원: 검색 정확도와 저장/연산 비용 간 균형. 1024차원이 현 프로젝트 규모에 적합
- 로컬 실행 가능: 외부 API 의존 없이 서버 내에서 추론 가능해야 함 (비용 절감, 지연시간 최소화)
- **Query-Document** 비대칭 처리: 검색 시 짧은 쿼리와 긴 문서 간의 의미 매칭이 잘 되어야 함

2.2 후보 모델 비교

항목	BAAI/bge-m3	intfloat/multilingual-e5-large
벡터 차원	1024	1024
최대 토큰	8,192	512
다국어 지원	100+ 언어	100+ 언어
입력 전처리	불필요	"query: " prefix 필수
MTEB 한국어 Retrieval	상위권	중상위권
모델 크기	~2.2GB	~2.2GB
추론 프레임워크	sentence-transformers	sentence-transformers

2.3 선정 결과: BAAI/bge-m3

bge-m3를 1차 임베딩 모델로 선정하였다.

- 선정사유
 - 최대 토큰 수 **8,192**: 현재 청킹 설정(1,000자, overlap 100자) 기준으로 청크가 잘릴 위험이 없다. multilingual-e5-large는 512토큰 제한으로 긴 청크에서 정보 손실이 발생할 수 있다.
 - 전처리 불필요: e5 계열은 쿼리와 문서에 각각 "query: ",

"passage: " prefix를 붙여야 하므로, 인덱싱과 검색 시 서로 다른 전처리 로직이 필요하다. bge-m3는 prefix 없이 동일한 방식으로 인코딩하므로 파이프라인이 단순해진다.

- 다국어 **Retrieval** 성능: MTEB 벤치마크에서 한국어를 포함한 다국어 검색 태스크에서 상위 성능을 보이며, Dense + Sparse + ColBERT 멀티 표현을 지원하여 확장 가능성이 높다.
- 검색-인덱싱 모델 일치: retriever에서 쿼리 임베딩 시 동일한 bge-m3 모델을 사용하여(embed_texts([query])[0]) 인덱싱과 검색 간 벡터 공간 불일치 문제를 원천 방지한다.

2.4 시스템 통합 구조

- [인덱싱] 크롤링 텍스트 → 청킹(1000자) → bge-m3 임베딩(1024d) → pgvector 저장 (HNSW 인덱스)
- [검색] 사용자 쿼리 → bge-m3 임베딩(1024d) → 코사인 유사도 검색 → Top-K 반환
 - 배치 크기: 32
 - 벡터 정규화: 활성화 (코사인 유사도 기반 검색에 최적화)
 - DB 인덱스: HNSW (m=16, ef_construction=64, vector_cosine_ops)

2.5 향후 계획

단계	내용
평가 체계 구축	RAGAS 기반 context_precision / context_recall 자동 평가 파이프라인 구축 중. TestsetGenerator를 활용한 테스트셋 자동 생성 예정.
OpenAI 임베딩 기준선 설정	text-embedding-3-large (3072d) / text-embedding-3-small (1536d)를 baseline으로 설정하여 검색 정확도 기준점 확보. 로컬 모델의 성능이 이 기준 대비 어느 수준인지 정량 비교.
로컬 모델 비교 실험	GPU 환경(RunPod) 확보 후 bge-m3 vs multilingual-e5-large 외에도 gte-multilingual-base, multilingual-e5-large-instruct 등 최신 로컬 모델 후보 추가 비교 (검색 정확도, 추론 속도, 메모리 사용량).

Reranker 도입	1차 벡터 검색(top-k) 결과를 Cross-Encoder 기반 리랭커로 재정렬하여 정밀도 향상. 후보: BAAI/bge-reranker-v2-m3 (bge-m3와 동일 계열, 다국어), ms-marco-MiniLM-L-12-v2. 벡터 검색의 recall + 리랭커의 precision 조합으로 2-stage retrieval 구성.
비용 효율 분석	로컬 GPU 운용 비용(RunPod 시간당 단가 x 추론량) vs OpenAI API 비용(토큰당 단가 x 호출량) 비교. 문서 규모와 호출 빈도에 따라 로컬이 유리한 손익분기점 산출.
최종 모델 확정	위 실험 결과를 종합하여 정확도·비용·지연시간 관점에서 최적 모델 확정. API 모델이 우세할 경우 로컬 모델 대신 API 전환도 고려.
칭킹 전략 연동 최적화	확정된 임베딩 모델에 맞춰 칭킹 파라미터(chunk_size, overlap, splitter 종류) 조합별 검색 품질 실험.