

데이터 수집 및 저장 수집 데이터 보고서

산출물 단계	데이터 수집 및 저장
평가 산출물	수집 데이터 보고서
제출 일자	26.02.25
깃허브 경로	https://github.com/skn21-final-1team
작성 팀원	우재현

1. 프로젝트 개요

사용자의 브라우저 북마크/URL을 지식 베이스로 활용하는 오픈소스 RAG(검색 증강 생성) 서비스로 단순 링크 저장을 넘어, 저장된 웹 콘텐츠를 분석하고 근거 기반으로 답변하는 지능형 도우미 구축합니다.

2. 수집 데이터 개요

데이터명	수집 대상	수집 목적	사용 예정 기능	출처/저작권
웹 페이지 추출 텍스트 데이터	사용자가 입력한 웹페이지 URL	NotebookLM 벤치마킹을 위한 사용자 맞춤형 문서 기반 QA, 텍스트 청킹(Chunking) 및 임베딩(Embedding) 처리	웹페이지 텍스트 추출, Markdown 변환, 청킹 및 벡터화 전처리	사용자가 입력한 불특정 웹사이트이며, 각 웹사이트의 저작권 정책에 따름

3. 수집 방법 및 자동화 절차

- 수집 방식

- 웹 크롤링
- 사용자 입력


- 수집 도구 또는 스크립트 설명:

- 사용한 언어/라이브러리: Python / urllib.robotparser(robots.txt 확인),
trafilatura(정적크롤링), BeautifulSoup(DuckDuckGo 우회 크롤링),

playwright(동적 크롤링 및 렌더링)

- 자동화 여부 및 주기: 실제 유저가 URL을 입력할 때마다 실시간으로 자동화된 파이프라인 실행
- 오류 발생 시 예외 처리 전략:
 1. 대상 웹사이트의 robots.txt를 우선 확인하여 수집 가능 여부 판별.
 2. trafalatura를 통한 1차 정적 크롤링 시도 (Google 검색 문서 등 차단이 예상되는 경우 DuckDuckGo 엔진과 BeautifulSoup을 활용해 우회 접근).
 3. 1차 크롤링 결과, 추출된 텍스트가 일정 글자 수 미만일 경우 동적 웹페이지로 간주하여 playwright를 통한 2차 크롤링(렌더링 후 추출) 진행.
 4. 추출된 텍스트 내에 가비지(Garbage) 데이터 패턴(예: unusual traffic, captcha, access denied, 404, 로그인 필요 등)이 정규식으로 감지될 경우 실패 처리 및 수집 중단.

흐름도



4.1 데이터 양

- 전체 수집 데이터 건수: 실시간 적재 예정이며 현재 테스트 단계로 약 140개 데이터를 진행했습니다.
- 추출된 고품질 데이터 건수 (필터링 후 기준): 필터링(가비지 텍스트 제거) 통과 및 Markdown 변환 성공 건수 기준 집계하며, 현재 테스트 단계로 약 100개의 데이터를 가지고 있습니다.

4.2 저장 위치 및 포맷

- 저장 경로: 현재 runpod에 postgresSQL DB서버에 저장 중이며, 배포단계에서 AWS RDS로 이전합니다.
- 저장 포맷: Markdown 텍스트 형태
- 인코딩: httpx의 response.txt를 통해 http 응답의 Content-Type헤더에 charset이 있으면 해당 인코딩을 사용하며, 누락 시 UTF-8로 간주하여 진행합니다.

5. 데이터 품질 및 정합성 관리 방안

- 중복 제거 기준: 웹페이지 갱신을 대비하여 중복 제거 하지 않습니다.
- 표준화 전략: 마크다운 텍스트의 공백, html, 제목, 리스트, 코드펜스, 테이블, 빈줄을 정규식으로 정규화하여 청킹 전 노이즈 제거