

SK네트웍스 Family AI과정 21기

모델링 및 평가 테스트 계획 및 결과 보고서

- 산출물 단계 : 모델링 및 평가
- 평가 산출물 : 테스트 계획 및 결과 보고서
- 제출 일자 : 2026.03.16
- 깃허브 경로 : <https://github.com/skn21-final-1team>
- 작성 팀원 : 우재현


1. 개요

1.1 목적

본 보고서는 RAG 파이프라인의 리트리버 단계에서 발생할 수 있는 검색 누락 및 노이즈 문제를 최소화하기 위해, 다양한 모델 및 전략 조합의 검색 성능을 테스트셋을 통해 정량적으로 평가하고 프로덕션에 적용할 최적의 아키텍처 구성을 도출하는 데 목적이 있다.

1.2 파이프라인 아키텍처

현재 RAG 파이프라인의 데이터 처리 및 검색 프로세스는 다음과 같이 구성된다.



1.3 테스트셋

항목	내용
질문 수	47개 (단일 소스 30개 + 복합 소스 17개)
ground_truth	사람이 직접 작성한 정답

단일소스 예시)

- **Question** : LightRAG 논문의 핵심 내용은 무엇인가요?

- **Ground_truth**: LightRAG은 기존 RAG의 단순한 데이터 표현과 부족한 맥락 이해 문제를 해결하기 위해 그래프 구조를 인덱싱 및 검색에 도입한 검색 기반 생성 시스템으로, 이중 검색 구조와 그래프+벡터 통합을 주요 특징으로 갖는다.

- **Question** : 우아한형제들에서 장애 대응 시 First Action이란 무엇이고 어떤 차이를 만드나요?

- **Ground_truth**: First Action은 장애 인지 이후 가장 먼저 취하는 초동 조치이다. 약 70여 건 이상의 장애 사례 분석 결과, 첫 조치로 롤백(Rollback)을 선택한 경우와 핫픽스(Hotfix)로 대응한 경우 사이에 장애 지속 시간과 고객 영향에서 뚜렷한 차이가 있었다.

복합소스 예시)

- **Question** : 카카오 Kanana-o와 DeepEval은 각각 AI 분야에서 어떤 역할을 하나요?

- **Ground_truth**: Kanana-o는 카카오의 옴니 모델로 한국어와 한국적 맥락을 이해하며 텍스트, 이미지, 오디오를 동시에 처리하는 AI 모델이다. DeepEval은 LLM 출력을 Pytest 방식으로 유닛 테스트하고 50개 이상의 평가 메트릭을 제공하는 LLM 평가 프레임워크이다.

- **Question** : 우아한형제들의 장애 대응 교훈과 JIRA를 마크다운으로 대체한 사례의 공통점은?

- **Ground_truth**: 우아한형제들은 70여 건의 장애 분석에서 First Action(초동 조치)으로 롤백을 선택한 경우가 핫픽스보다 장애 시간이 짧았다. JIRA를 마크다운으로 대체한 팀은 4,200개 이슈에서 티켓 찾는 데 11분이 걸리던 문제를 해결하고 배포 빈도를 3배로 올렸다. 두 사례 모두 빠르고 단순한 조치가 핵심이다.

2. 평가 방법론

2.1 프레임워크

항목	내용
평가 방법론	RAGAS (Es et al., 2023)
구현 프레임워크	DeepEval
LLM Judge	OpenAI gpt-4o-mini

DeepEval은 RAGAS 논문의 평가방식을 따르면서, 다른 도구에 의존성 할 필요 없이 독립적으로 사용할 수 있으며, 파이썬 표준 테스트 도구인 **pytest**를 지원하여 CI/CD 통합이 용이하다는 장점이 있기에

채택하였다.

2.2 평가 지표

지표	측정 대상	설명
Contextual Precision	순위 품질	관련 context가 상위 순위에 있는가
Contextual Recall	정보 커버리지	ground_truth에 필요한 정보를 context가 얼마나 포함하는가
Contextual Relevancy	노이즈 비율	검색된 context 중 질문에 관련 있는 비율

지표 우선순위: Recall > Precision > Relevancy

사유: 필요한 정보가 검색되지 않으면 LLM이 답변할 수 없으므로 recall 지표를 제일 우선으로 하며, 관련 context가 상위에 위치하는지를 평가하는 precision이 2순위, 노이즈 비율을 제공하는 relevancy가 3순위로 선정하였다.

2.3 평가 프로세스

질문 → 벡터 검색(top_k=5 | rerank 시 20) → base or Reranker →
검색된 chunks → DeepEval (gpt-4o-mini) → C.Precision / C.Recall / C.Relevancy

3. 실험 설계

3.1 독립변수

변수	후보	비고
임베딩 모델(2종)	BAAI/bge-m3 (1024차원), Qwen3-Embedding-8B (4096차원)	다국어 범용 vs 한국어 강점
칭킹 전략(3종)	Semantic Auto, Contextual, HierarchicalPrepend	임베딩 기반 / LLM 기반 / 구조 기반
리랭커	bge-reranker-v2-m3	Cross-Encoder 기반 재정렬

3.2 청킹 전략 상세

전략	접근 방식	chunk_size	특징
Semantic Auto	임베딩 유사도 기반 경계 탐지	자동	자동 분할, 추가 비용 없음
Contextual	마크다운 분할 + gpt-4o-mini 맥락 요약 prepend	800	LLM 요약 비용 발생
HierarchicalPrepend	헤더 기반 분할 + 재귀 분할 + 헤더 경로 prepend	1000	문서 구조 활용, 비용 없음

- Contextual(800): 각 청크에 gpt-4o-mini가 생성한 맥락 요약(1~2문장, 약 100~150자)이 prepend된다. 원본 청크 + 요약이 합쳐져 실효 크기가 ~950자로 늘어나므로, 임베딩 모델의 512 토큰 권장 입력 범위를 초과하지 않도록 원본을 800으로 설정했다.

- HierarchicalPrepend(1000): 헤더 경로(약30~60자)만 prepend되어 오버헤드가 작다. 기술 블로그 특성상 하나의 소주제를 완결적으로 담으려면 800자로는 문단이 중간에 잘리는 경우가 빈번하여, 1000자로 설정해 정보 완결성을 높였다.

3.3 고정 조건

항목	값
테스트셋	47개 질문
top_k	5
Reranker fetch_k	20 (벡터검색 top-20 → 리랭크 top-5)
DB	PostgreSQL + PGVector
임베딩/리랭커 인프라	RunPod Serverless (GPU)

4. 실험 결과(47개 테스트셋 기준)

실험순서	임베딩 모델	청킹 전략	리랭커	C.Preci sion	C.Recall	C.Relevan cy
------	-----------	-------	-----	-----------------	----------	-----------------

1	bge-m3	Semantic Auto	-	0.882	0.909	0.581
2	bge-m3	Contextual	-	0.889	0.934	0.587
3	bge-m3	HierarchicalPrepend	-	0.889	0.897	0.584
4	bge-m3	Semantic Auto	reranker	0.919	0.933	0.598
5	bge-m3	Contextual	reranker	0.894	0.933	0.593
6	bge-m3	HierarchicalPrepend	reranker	0.926	0.933	0.606
7	Qwen3	Semantic Auto	-	0.813	0.865	0.325
8	Qwen3	Contextual	-	0.835	0.926	0.568
9	Qwen3	HierarchicalPrepend	-	0.836	0.904	0.552
10	Qwen3	Semantic Auto	reranker	0.863	0.862	0.280
11	Qwen3	Contextual	reranker	0.908	0.933	0.547
12	Qwen3	HierarchicalPrepend	reranker	0.876	0.902	0.554

5. 분석

5.1 임베딩 모델

6건 평균 기준, bge-m3가 Precision +0.045, Recall +0.024, Relevancy +0.121로 모든 지표에서 Qwen3를 상회한다. 특히 Qwen3 + Semantic Auto 조합은 Relevancy 0.28~0.33으로 노이즈가 심각하여, 청킹 전략에 관계없이 bge-m3가 안정적이다.

5.2 청킹 전략

bge-m3 Baseline에서 세 전략 간 Precision/Relevancy 차이는 0.01 이내로 미미하다. Recall만 Contextual(0.934) > Semantic(0.909) > Hierarchical(0.897) 순으로 유의미한 차이를 보인다. 다만 Contextual은 청크당 gpt-4o-mini 호출 비용이 발생하며, 리랭커 병용 시 HierarchicalPrepend가 동일 Recall(0.933)에 도달하므로 비용 대비 효과는 HierarchicalPrepend + Reranker가 최적이다.

5.3 리랭커

bge-m3 + HierarchicalPrepend에서 리랭커가 Precision +0.037, Recall +0.036, Relevancy +0.022로 세 지표 모두 최고 개선폭을 보인다. 반면 Qwen3에서는 Precision만 소폭 개선되고 Relevancy는 오히려 하락하는 경향이 있어, 벡터 검색 자체의 품질이 낮으면 리랭커의 재정렬 효과도 제한적임을 확인했다.

6. 결론

6.1 최종 권장 구성

항목	권장	근거
임베딩 모델	BAAI/bge-m3	모든 지표에서 Qwen3 상회 (Precision +0.045, Recall +0.024, Relevancy +0.121)
청킹 전략	HierarchicalPrepend	리랭커 병용 시 최고 종합 성능, 추가 비용 없음
리랭커	bge-reranker-v2-m3	Precision +0.037, Recall +0.036 개선 (HierarchicalPrepend 기준)

6.2 최종 성능

지표	점수	해석
Contextual Precision	0.926	관련 context가 상위 순위에 잘 배치됨
Contextual Recall	0.933	정답에 필요한 정보의 93%를 검색
Contextual Relevancy	0.606	top-5 중 약 3개가 질문과 관련

참고문헌

- Es, S., et al. (2023). "RAGAS: Automated Evaluation of Retrieval Augmented Generation." *arXiv:2309.15217*
- DeepEval Documentation